Programa de Verão

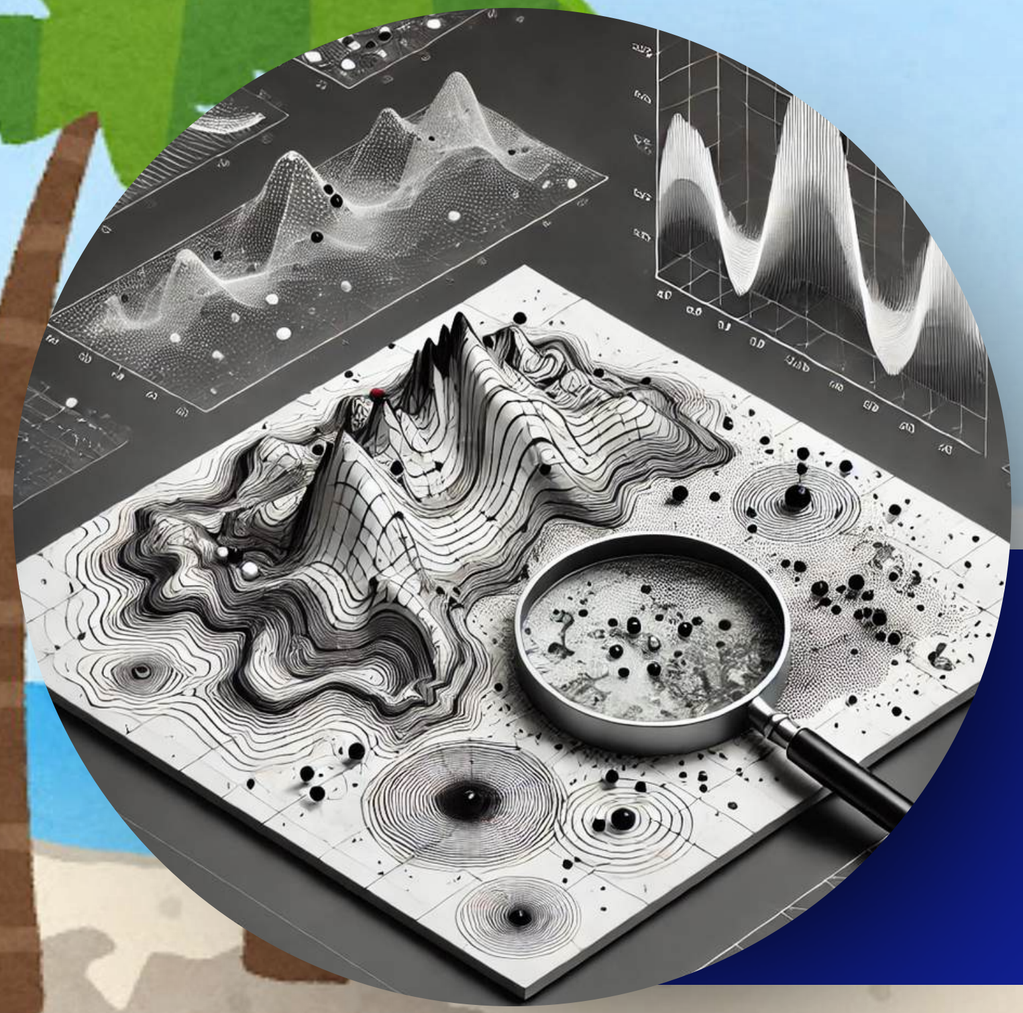

03 e 05 de Março

Modelos de **Regressão Espacial** para Áreas e **Geoestatística** aplicada a dados não normais

UNIVERSIDADE FEDERAL DE LAVRAS

PPG em Estatística e Experimentação Agropecuária

Daví Barbosa Pereira de Sousa

Marcela Silva de Araujo

Sumário

- Módulo I: Modelos de Regressão Espacial para Áreas
- Módulo II: Geoestatística Aplicada a Dados Não Normais

MÓDULO I

MODELOS DE REGRESSÃO ESPACIAL PARA ÁREAS

03 de Março de 2026

Introdução

DADOS DE ÁREAS

Dados de áreas são informações associadas a sub-regiões que formam uma divisão de domínio contínuo, além disso, eles podem ser chamados também de dados de superfície discreta (Scalon, 2024).

OBJETIVO

Modelar a relação entre uma variável resposta e covariáveis levando em conta que áreas vizinhas tendem a ser parecidas.

CONCEITOS BÁSICOS ATÉ CHEGAR AOS MODELOS ESPACIAIS

- Polígonos;
- Vizinhança espacial e matriz de pesos;
- Dependência espacial.

TIPOS DE DADOS

- Saúde (Cortez *et al.*, 2023);
- Socioeconômicos (Carral *et al.*, 2025);
- Infraestrutura (Sipos; Aferwork Mekonnen; Szabó, 2021);
- Florestais (Martins; Francisco, 2025).

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Polígonos

No contexto da estatística espacial, os polígonos representam as áreas estudadas, como bairros, municípios, estados, setores, etc.

É possível obter polígonos, ou a malha espacial, no site do Instituto Brasileiro de Geografia e Estatística (IBGE).

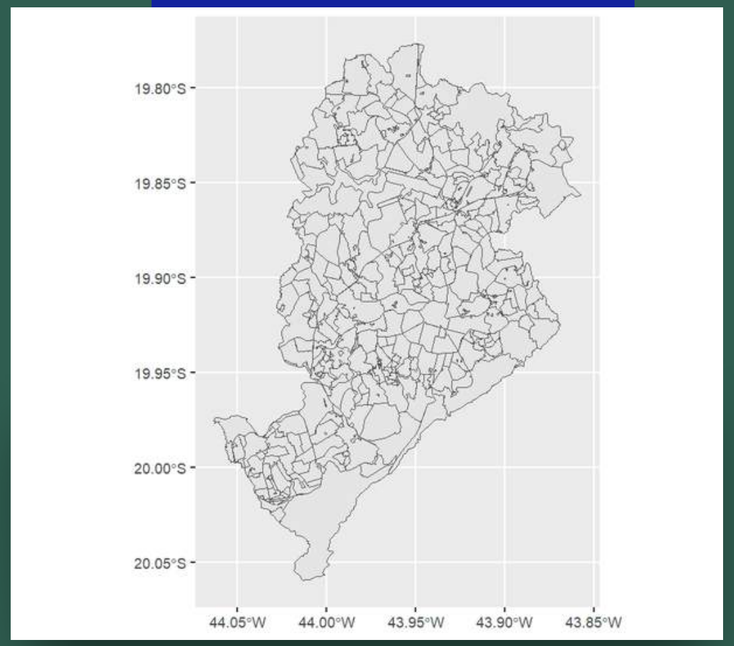

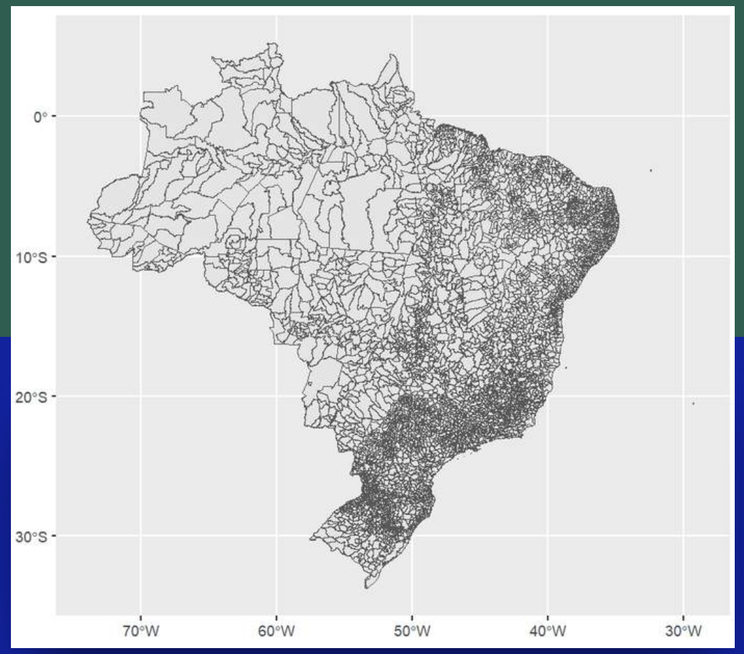

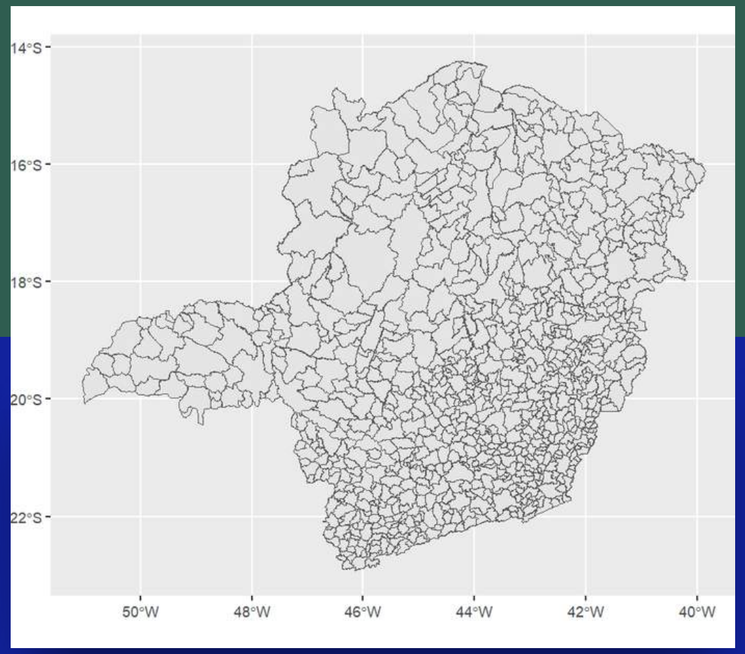

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Vizinhança espacial

Como o nome sugere, a vizinhança espacial pode ser entendida como quando um polígono está próximo a outro de acordo com a condição adotada. Tal condição pode ser distância, fronteira, etc.

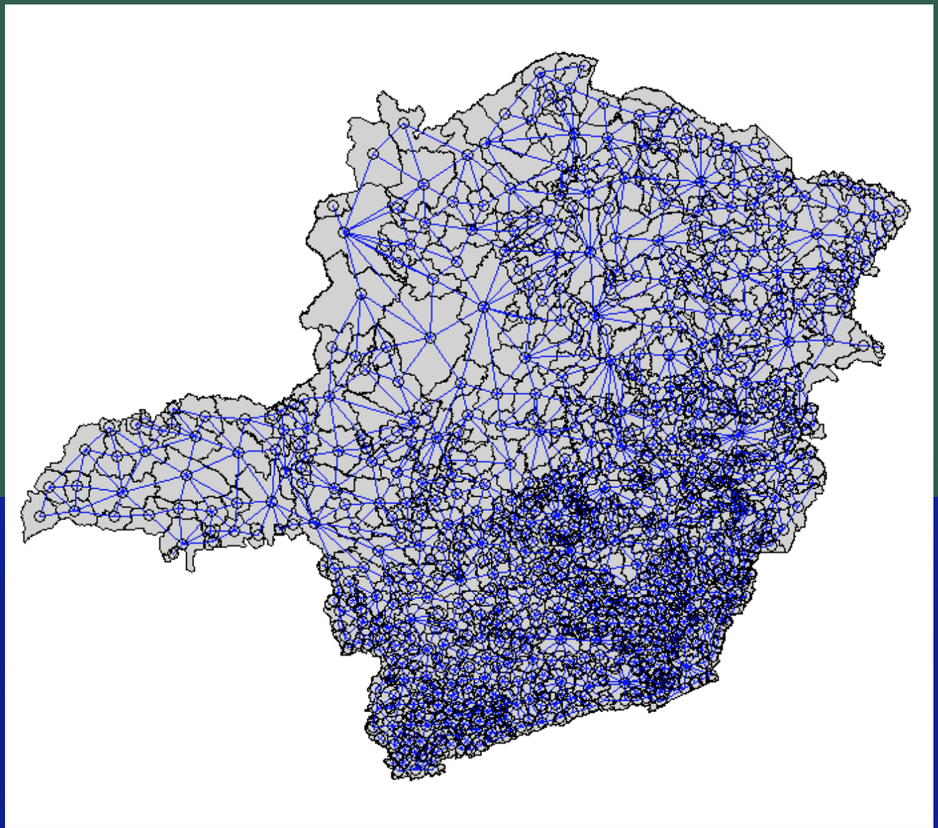

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Matriz de pesos

Contiguidade: Define conexões entre regiões adjacentes

- Rainha: Uma unidade é vizinha se compartilha pelo menos um vértice ou borda;
- Torre: Uma unidade é vizinha se compartilha apenas uma borda;
- Bispo: Considera apenas vértices em comum.

Similaridade: Não considera apenas a localização, usa características das observações para definir a vizinhança

- Similaridade socioeconômica;
- Características ambientais semelhantes.

Distância: Define vizinhos com base na distância entre os centroides das regiões

- Distância fixa: Todos os pontos dentro de um raio d são considerados vizinhos;
- k-vizinhos mais próximos: Cada unidade tem exatamente k vizinhos mais próximos;
- Funções de decaimento: Usa funções (exponenciais, gaussianas) para ponderar os pesos conforme a distância aumenta.

Normalizada

- Normaliza os pesos para que a soma de cada linha seja igual a 1, garantindo interpretação estatística consistente.

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Dependência Espacial

Para que seja possível prosseguir com análises espaciais no contexto de dados áreas, é verificado se há dependência espacial por meio de índices. Dentre os quais se destacam:

- Índice de Moran: é a estatística mais utilizada para verificação de autocorrelação espacial em dados de área; é um produto cruzado da variável estudada em um polígono com esta mesma nos vizinhos;

- Índice de Geary: um alternativa mais sensível (para captar autocorrelação espacial) ao Moran; Utiliza o produto cruzado da diferença entre os pares da variável de estudo.

Nesse minicurso, utilizaremos o índice de Moran global.

ÍNDICE DE MORAN GLOBAL

Mede a autocorrelação espacial de uma variável para toda a região estudada. Indica se há um padrão espacial significativo na distribuição dos dados. Suas hipóteses são as seguintes:

$$\begin{cases} H_0: \text{A variável de estudo está distribuida de forma aleatória no espaço} \\ H_1: \text{A variável de estudo sofre mudanças de acordo com o local amostrado} \end{cases}$$

Além disso,

- Valores positivos do I indicam que locais com valores semelhantes (alto com alto, baixo com baixo) tendem a estar agrupados.
- Valores negativos do I indicam que valores altos estão próximos de valores baixos (padrão de dispersão).
- I próximo de zero sugere que os valores estão distribuídos aleatoriamente no espaço.

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Índice de Moran Global

A fórmula do Índice de Moran Global:

$$I = \frac{N}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij}(x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2}$$

onde:

- N é o número total de observações,
- x_i e x_j são os valores da variável em locais i e j,
- $\bar{x}$ é a média da variável,
- w_{ij} são os pesos espaciais que definem a vizinhança.

Seus valores estão contidos principalmente no intervalo [-1;1], podendo assumir qualquer valor no conjunto dos reais.

Modelos de Regressão Espacial

Em dados georreferenciados agregados por áreas, a presença de autocorrelação espacial compromete a validade dos modelos clássicos de regressão, motivando o uso de modelos autoregressivos espaciais.

Nesse contexto, tornam-se necessários modelos que incorporem explicitamente a estrutura de dependência espacial, como os modelos autorregressivos espaciais (ANSELIN, 1988).

MODELO AUTOREGRESSIVO SIMULTÂNEO (SAR)

MODELO DE ERRO ESPACIAL (CAR)

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Modelo Autorregressivo Simultâneo (SAR)

Sua formulação é dada por:

$$y = \rho W_1 y + X\beta + \epsilon, \quad \epsilon \sim N(0, \sigma^2 I)$$

onde:

- y é a variável dependente;
- ρ é o parâmetro espacial responsável pela mensuração do grau de dependência espacial da variável dependente e seus respectivos vizinhos;
- W_1 é a matriz de vizinhança;
- i X são as variáveis independentes;
- β são os coeficientes da regressão;
- ε é o erro aleatório;
- σ^2 é a variância do modelo;
- I é uma matriz identidade.

Modelo Autorregressivo Simultâneo (SAR)

No modelo SAR a variável dependente é explicada por seus vizinhos e por covariáveis. Ou seja, a informação dos vizinhos é introduzida no modelo por meio da matriz de vizinhanças.

A autocorrelação espacial é representada por um único parâmetro, adicional ao modelo clássico de regressão, que múltiplica a matriz de vizinhança. Quando não dependência espacial, o modelo é como o usual.

Por este motivo, o resíduo é modelado de tal forma que os erros dependem uns dos outros.

$$e_i = \sum_{j=1}^{n} b_{ij} e_i + \varepsilon_i$$

em que, ε_i representam os erros aleatórios não correlacionados, que seguem uma distribuição normal com média zero e matriz de covariância $\Sigma\varepsilon$, cujos elementos na diagonal correspondem às variâncias constantes.

Modelo Autorregressivo Simultâneo (SAR)

O modelo pode ser escrito como

$$\mathbf{Z} = \boldsymbol{\mu} + \mathbf{e}$$

do qual, o termo de erros expresso matricialmente é

$$\mathbf{e} = \mathbf{B}(\mathbf{Z} - \mathbf{X}^T\boldsymbol{\beta}) + \boldsymbol{\varepsilon}$$

então, o modelo passa a ser escrito como

$$\mathbf{Z} = \mathbf{X}^T\boldsymbol{\beta} + \mathbf{B}(\mathbf{Z} - \mathbf{X}^T\boldsymbol{\beta}) + \varepsilon$$

em que, β é a matriz que contém os parâmetros b_{yj} e $\mathbf{I}$ é a matriz identidade. $\mathbf{Z}$ é a variável resposta, $\boldsymbol{\mu}$ é o vetor de médias das áreas que pode ser modelado de diversas formas e $\mathbf{e}$ é o vetor de erros aleatórios.

Modelo Autorregressivo Simultâneo (SAR)

Por se tratar de uma combinação linear de variáveis aleatórias NORMAIS, Z seguirá uma distribuição normal com média dada por:

$$\mathbf{E}[\mathbf{Z}] = \mathbf{X}^T \boldsymbol{\beta}$$

e a matriz de variâncias e covariâncias:

$$\mathrm{Var}[\mathbf{Z}] = \sigma^2 (\mathbf{I} - \mathbf{B})^{-1} (\mathbf{I} - \mathbf{B}^T)^{-1}$$

Reparametrização do Modelo (SAR)

Uma reparametrização bastante usual do modelo SAR, apresentada por ANSELIN(1999), considera $\mathbf{B} = \lambda\mathbf{W}$ em que $\boldsymbol{\lambda}$ é parâmetro de autocorrelação espacial e W é uma matriz simétrica que representa a dependência espacial, com isso o modelo SAR:

$$\mathbf{Z} = (\mathbf{I} - \lambda\mathbf{W})^{-1}\mathbf{X}\boldsymbol{\beta} + (\mathbf{I} - \lambda\mathbf{W})^{-1}\boldsymbol{\varepsilon}$$

em que a variãncia de Z :

$$\mathrm{Var}[\mathbf{Z}] = \sigma^2(\mathbf{I} - \lambda\mathbf{W})^{-1}(\mathbf{I} - \lambda\mathbf{W}^T)^{-1}$$

Reparametrização do Modelo (SAR)

O logaritmo da função de verossimilhança é dado como

$$\ln\left(L(\boldsymbol{\beta}, \sigma, \lambda \mid \mathbf{Z}, \mathbf{X})\right) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) + \ln|\mathbf{I} - \lambda\mathbf{W}| \\ -\frac{1}{2\sigma^2}(\mathbf{Z} - \lambda\mathbf{W}\mathbf{Z} - \mathbf{X}\boldsymbol{\beta})^T(\mathbf{Z} - \lambda\mathbf{W}\mathbf{Z} - \mathbf{X}\boldsymbol{\beta})$$

Para obter os estimadores de máxima verossimilhança, deriva-se esta equação em relação aos parâmetros e iguala a zero, para obter o sistema de equações conhecidas como equações de escore.

São necessários métodos iterativos para obter as estimativas MV de β e λ pois as equações de escore não retornam solução fechada.

Pressupostos do Modelo SAR

$$y = \rho W_1 y + X\beta + \epsilon, \quad \epsilon \sim N(0, \sigma^2 I)$$

- A matriz de pesos espaciais W é conhecida e corretamente especificada;
- (I-ρW)é não singular (invertível);
- O parâmetro espacial ρ é diferente de zero;
- Os erros são normais:
- Não há autocorrelação espacial no termo de erro (a dependência está na variável dependente, não no erro);
- Não há multicolinearidade perfeita em X.

Modelo de Erro Espacial (CAR)

O modelo, conforme Anselin (1999):

$$\mathbf{Z} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$
$$\boldsymbol{\varepsilon} = \lambda \mathbf{W} \boldsymbol{\varepsilon} + \mathbf{e}$$

- Z é o vetor de observações da variável dependente (n × 1);
- X é a matriz de variáveis explicativas (n × p);
- β é o vetor de parâmetros da regressão (p × 1);
- ε é o termo de erro espacial;
- λ é o coeficiente de autocorrelação espacial associado ao erro;
- W é a matriz de pesos espaciais (matriz de proximidade);
- e é o componente do erro não correlacionado;
- σ^2 é a variância do termo de erro;
- I é a matriz identidade de ordem n.

Reparametrização do Modelo (CAR)

Anselin (1999) mostra que uma das reparametrizações é dada por:

$$\mathbf{Z} = \mathbf{X}\boldsymbol{\beta} + (\mathbf{I} - \lambda\mathbf{W})^{-1}\mathbf{e} \quad \text{com} \quad \mathbf{e} \sim N(\boldsymbol{\phi}, \mathbf{I}\sigma^2).$$

Como é uma combinação linear de variáveis aleatórias normais, Z terá distribuição normal com média e matriz de variâncias e covariâncias:

$$E[\mathbf{Z}] = \mathbf{X}\boldsymbol{\beta}$$

e

$$\text{Var}[\mathbf{Z}] = \boldsymbol{\Sigma}_{\mathbf{Y}} = \sigma^2(\mathbf{I} - \lambda\mathbf{W})^{-1}(\mathbf{I} - \lambda\mathbf{W}')^{-1}$$

Reparametrização do Modelo (CAR)

O logaritmo da função de verossimilhança conforme Anselin (1999):

$$\ln L(\boldsymbol{\beta}, \sigma^2, \lambda \mid \mathbf{Z}, \mathbf{X}) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) + \ln|\mathbf{I} - \lambda\mathbf{W}| - \frac{1}{2\sigma^2}(\mathbf{Z} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{I} - \lambda\mathbf{W})'(\mathbf{I} - \lambda\mathbf{W})(\mathbf{Z} - \mathbf{X}\boldsymbol{\beta})$$

Deriva-se esta equação em relação aos parâmetros e iguala a zero, para obter o sistema de equações.
Também são necessários métodos iterativos, semelhante ao SAR.

Pressupostos do Modelo CAR

$$\mathbf{Z} = \mathbf{X}\boldsymbol{\beta} + (\mathbf{I} - \lambda\mathbf{W})^{-1}\mathbf{e} \quad \text{com} \quad \mathbf{e} \sim N(\boldsymbol{\phi}, \mathbf{I}\sigma^2).$$

- A matriz $\mathbf{W}$ deve ser simétrica;
- $(\mathbf{I} - \lambda\mathbf{W})$ deve ser invertível;
- O parâmetro λ deve garantir que a matriz de variância-covariância seja definida positiva;
- O termo $\mathbf{e}$ segue distribuição normal com média constante e variância constante;
- A matriz de variância resultante deve ser definida positiva;
- Independência condicional: cada unidade depende apenas dos vizinhos definidos em $\mathbf{W}$.

Aplicações dos modelos SAR e CAR

Aplicação 1 – Saúde (Cortez et al., 2023):

- O objetivo central foi avaliar como variáveis sociais e de saúde influenciaram a disseminação da COVID-19 nos municípios de Minas Gerais, considerando explicitamente a dependência espacial entre eles.
- A variável resposta foi a incidência (ou taxa de casos confirmados) de COVID-19 nos municípios de Minas Gerais.
- Variáveis explicativas:
  - Taxa de vulnerabilidade social;
  - Subíndice de longevidade do IDHM;
  - Subíndice de infraestrutura urbana do IVS;
  - Taxa de envelhecimento.
- Modelo utilizado: SAR.
- A modelagem SAR evidenciou autocorrelação espacial significativa na incidência de COVID-19, demonstrando que a incorporação da dependência espacial foi essencial para estimativas consistentes dos efeitos socioestruturais.

Aplicações dos modelos SAR e CAR

Aplicação 2 – Socioeconômicos (Carral et al., 2025):

- O objetivo central foi Investigar como a vulnerabilidade socioeconômica influencia o impacto das inundações.
- A variável resposta foi a Impacto das inundações, medido por indicadores como: Danos às residências; População afetada; Intensidade do impacto por unidade espacial.
- Variáveis explicativas:
  - Ensino superior;
  - Alta riqueza;
  - Poupança;
  - Propriedades de imóveis entre outras.
- Modelo utilizado: SAR.
- A presença de dependência espacial significativa evidenciou que o impacto das inundações apresenta padrão de aglomeração territorial, e que a incorporação do componente espacial foi fundamental para obter estimativas robustas dos efeitos da vulnerabilidade socioeconômica.

Aplicações dos modelos SAR e CAR

Aplicação 3 – Infraestrutura (Sipos; Aferwork Mekonnen; Szabó, 2021):

- O objetivo foi investigar os determinantes dos acidentes de trânsito incorporando explicitamente a dependência espacial entre unidades territoriais.
- A variável dependente foi o número de acidentes de trânsito registrados nas unidades espaciais analisadas.
- Variáveis explicativas:
  - Densidade populacional;
  - Infraestrutura viária;
  - Indicadores econômicos;
  - Nível de motorização;
  - Características estruturais do território.
- Modelo utilizado: SAR e CAR.
- A superioridade do SAR sugere que os acidentes de trânsito apresentam interdependência territorial direta, caracterizando um processo espacial de propagação e não apenas correlação residual.

Aplicações dos modelos SAR e CAR

Aplicação 4 – Florestais (Martins; Francisco, 2025):

- O objetivo central foi identificar os determinantes do desmatamento na Amazônia, distinguindo padrões históricos e recentes, incorporando explicitamente a dependência espacial entre unidades territoriais.
- A variável dependente foi a taxa de desmatamento.
- Variáveis explicativas:
  - Estrutura fundiária;
  - Atividade agropecuária;
  - Infraestrutura (como rodovias);
  - Dinâmica econômica local;
  - Características institucionais e de governança, entre outros.
- Modelo utilizado: SAR.
- A evidência de autocorrelação espacial e o modelo SAR em relação indicam que o desmatamento na Amazônia apresenta efeito de transbordamento territorial, tornando indispensável a incorporação da dependência espacial para estimativas consistentes.

Vamos à prática!!!

UTILIZAREMOS O SOFTWARE RSTUDIO PARA ESTA PRÁTICA. ACOMPANHEM CONOSCO!

SOBRE A APLICAÇÃO:

- Estudo epidemiológico: taxa (1:100.000) de incidência de dengue em Minas Gerais no ano de 2024;
- Dados disponíveis no IDSC-BR, versões 2024 e 2025;
- Seremos capazes de identificar se a localidade está influenciando de alguma forma nas taxas e os efeitos de variáveis explicativas.

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Referências

ANSELIN, L. *Spatial econometrics: methods and models*. Dordrecht: Kluwer Academic Publishers, 1988.

ANSELIN, L. Spatial econometrics. 1999.

BURT, James E.; BARBER, Gerald M.; RIGBY, David L. *Elementary statistics for geographers*. Guilford Press, 2009.

CARRAL, Carolina Ferman et al. Spatial econometric modeling of socioeconomic vulnerability and flood impact: Towards a risk-layering approach in southern Malawi. *International Journal of Disaster Risk Reduction*, v. 121, p. 105433, 2025.

CORTEZ, Matheus Luiz J.; AZEVEDO, Úrsula Ruchkys de; CAMPOS JÚNIOR, Edimar Olegário de; NASCIMENTO, Danilo Cirino Muniz do; DIOGO, Anacleto Marito; COELHO, Vagner Braga Nunes; BARBOSA, David Soeiro; RIBEIRO, Sônia Maria Carvalho. WHAT ROLE DO SOCIAL VARIABLES AND HEALTH PLAY IN THE SPREAD OF COVID-19 IN THE STATE OF MINAS GERAIS – BRAZIL?. *Caderno de Geografia*, Belo Horizonte, v. 33, n. 72, p. 317, 2023.

MARTINS, Henrique Parizotto Lacaz; FRANCISCO, Eduardo de Rezende. Determinantes do desmatamento histórico e recente da Amazônia na perspectiva da estatística espacial. *Cadernos Gestão Pública e Cidadania*, v. 30, p. e91454, 2025.

SCALON, J. D. *Análise de dados espaciais com aplicações em R*. Lavras: UFLA, 2024. 275 p. ISBN 978-85-8127-185-9.

SIPOS, Tibor; AFEWORK MEKONNEN, Anteneh; SZABÓ, Zsombor. Spatial econometric analysis of road traffic crashes. *Sustainability*, v. 13, n. 5, p. 2492, 2021.

Tem dúvidas? Pergunte!

SINTA-SE À VONTADE PARA TIRAR SUAS DÚVIDAS CONOSCO!

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Obrigado(a)!

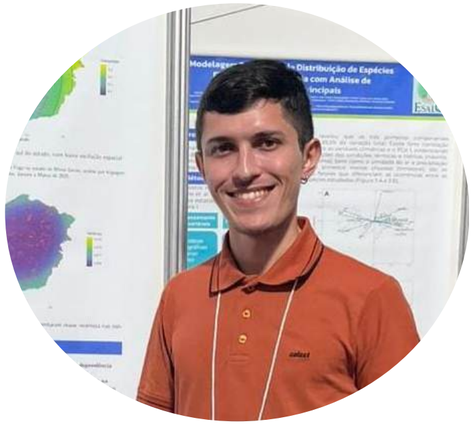

DAVÍ BARBOSA PEREIRA DE SOUSA

Doutorando em Estatística e Experimentação Agropecuária UFLA

Contatos:

Institucional: davi.sousa1@estudante.ufla.br

Profissional: davibarbosa.prof@gmail.com

Lattes: http://lattes.cnpq.br/4206431803366749

MARCELA SILVA DE ARAUJO

Doutoranda em Estatística e Experimentação Agropecuária UFLA

Contatos:

Institucional: marcela.araujo2@estudante.ufla.br

Profissional: marcelaaraujo.prof@gmail.com

Lattes: http://lattes.cnpq.br/8522510498165639

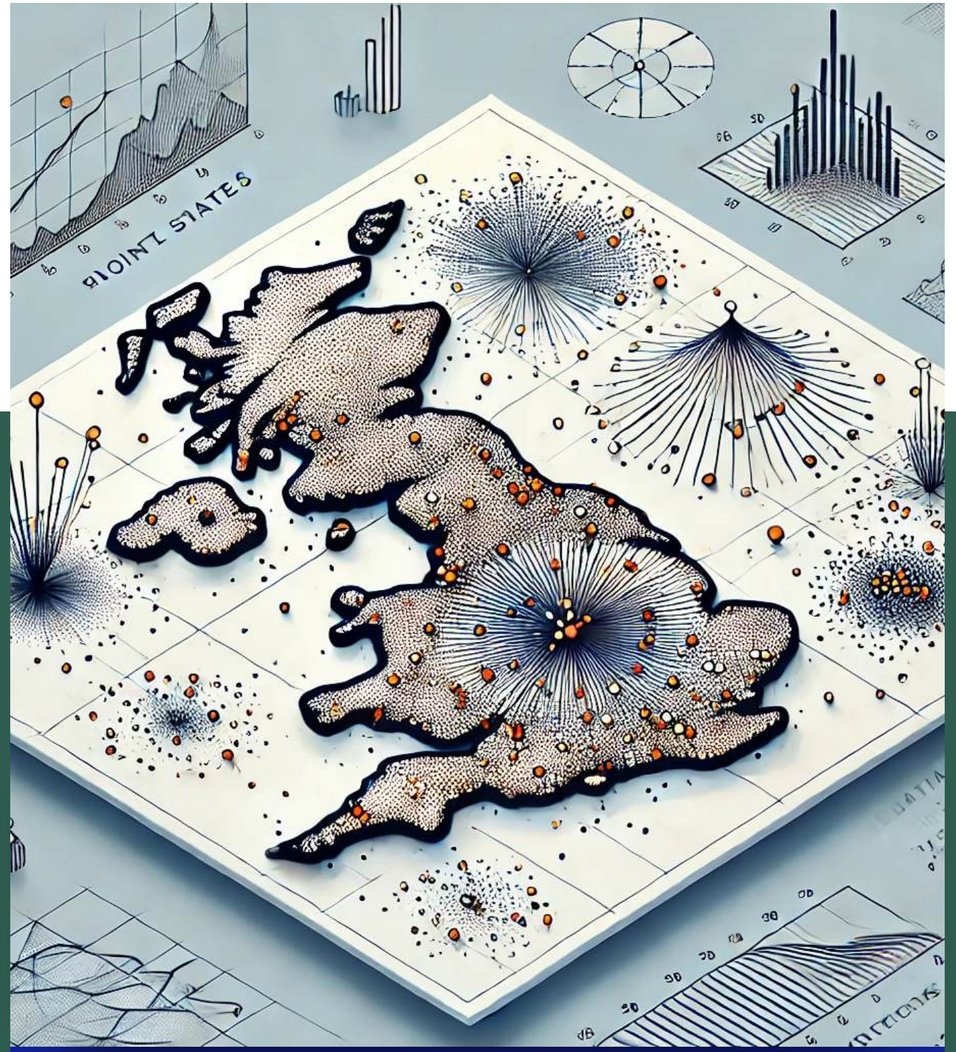

MÓDULO II

GEOESTATÍSTICA APLICADOS A DADOS NÃO NORMAIS

05 de Março de 2025

Breve Introdução

DADOS ESPACIAIS PARA GEOESTATÍSTICA

São variáveis que estão distribuídas de forma contínua no espaço, que não dependem de polígonos e nem da sua posição georreferenciada.

OBJETIVO

Estimar o valor da variável em questão para qualquer posição na superfície, com base nos dados amostrados.

CONCEITOS BÁSICOS

- Semivariograma;
- Tendência;
- Anisotropia;
- Modelos Teóricos;
- Estimação: MMQ.

TIPOS DE DADOS

- Mineração (Zhexenbayeva *et al.*, 2024);
- Meteorologia (Guimarães; Alves, 2023);
- Agricultura (Wani *et al.*, 2024);
- Saúde (Goovaerts, 2014).

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Semivariograma

Mede como a variabilidade de um atributo muda com a distância entre os pontos amostrais. Há dois principais motivos para seu uso:

1. Análise da estrutura espacial: permite identificar a escala de dependência espacial de uma variável, ajudando a entender até que distância os dados estão correlacionados;
2. Krigagem: técnica utilizada para realizar previsões.

Além disso, pode-se ajustar a diversos modelos, dependendo da disposição dos dados.

Tendência

Indica que o campo aleatório não possui média constante.

Principais implicações:

- Viola o pressuposto de estacionariedade;
- Pode mascarar a real estrutura de dependência espacial;
- Afeta a interpretação do variograma.

Como tratar:

- Remoção da tendência (detrending)
- Modelagem explícita via covariáveis

Passos pra trabalhar a tendência:

1. Ajustar o modelo aditivo para tendência:

$$\mu^*(x_i, y_j) = b_0 + b_1 x_i + b_2 y_j + b_3 x_i^2 + b_4 y_j^2 + b_5 x_i y_j$$

em que:

- $\mu^*(x_i, y_j)$ é a estimativa da superfície de tendência;
- (x_i, y_j) são as coordernadas das posições das amostras;
- b_i são as estimativas dos parâmetros do modelo de regressão.

Observação:

- Iniciar com os modelos de menor ordem.

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Passos pra trabalhar a tendência:

2. O modelo ajustado de tendência é extraído dos dados originais $z(x_i, y_j)$, dando origem aos resíduos $z_{\text{res}}(x_i, y_j)$.

$$z_{\text{res}}(x_i, y_j) = z(x_i, y_j) - \mu^*(x_i, y_j)$$

3. Calcular o variograma, ajustar e validar o modelo teórico e realizar a krigagem utilizando os resíduos.

4. Construir a superfície de krigagem na escala original dos dados:

$$z(x_i, y_j) = \mu^*(x_i, y_j) + z_{\text{res}}(x_i, y_j)$$

Observação:

- Modificação na escala dos dados mas não muda a estrutura de dependência espacial.
- Caso necessário, repetir o processo.

Anisotropia

Em Geoestatística, a anisotropia ocorre quando a estrutura de dependência espacial de uma variável regionalizada (VR) varia conforme a direção considerada.

Formalmente, o semivariograma deixa de depender apenas da distância h e passa a depender também da direção θ:

$$\gamma(h) \neq \gamma(h, \theta)$$

Ou seja, a continuidade espacial não é a mesma em todas as direções.
Isso contrasta com a isotropia, onde a variabilidade depende apenas da distância.

Tipos de Anisotropia

Existem três classificações principais:

1. Anisotropia Geométrica: O patamar (sigma_2) é o mesmo em todas as direções, mas o alcance (phi) muda.

Pode ser corrigida por transformação geométrica do sistema de coordenadas (reescala do eixo principal).

2. Anisotropia Zonal: O patamar é diferente conforme a direção.

Não pode ser corrigida apenas com transformação geométrica. Geralmente requer modelagem mais complexa (ex.: combinação de estruturas).

3. Anisotropia Mista: Combinação da anisotropia geométrica e zonal.

Fenômenos ambientais complexos com múltiplos processos atuando simultaneamente.

Observações sobre Anisotropia

- A anisotropia deve ser corrigida ou modelada para obter um variograma isotrópico (mesmo nugget, range e sill em todas as direções).

- Se a variabilidade espacial for isotrópica, pode-se estimar diretamente o variograma empírico omnidirecional.

- Se for anisotrópica, é necessário:
  - Identificar o tipo de anisotropia;
  - Corrigi-la antes de ajustar o modelo teórico.

- A anisotropia geométrica é a mais simples de corrigir, geralmente por rotação ou reescala das coordenadas.

- A anisotropia zonal ou mista é mais complexa, exigindo modelos anisotrópicos específicos.

Correção da Anisotropia Geométrica

- Identificar as direções de maior e menor continuidade espacial e calcular a razão de anisotropia (Fa).
- Determinar o ângulo de anisotropia (θ) entre o norte (0°) e a direção de maior continuidade.
- Realizar a rotação dos eixos, alinhando o maior eixo da elipse ao norte.
- Aplicar reescala, transformando a elipse em um círculo com raio igual ao menor eixo.

Modelos Teóricos

O ajuste de modelos ao semivariograma é indispensável, pois:

- Ajuda a suavizar a variação amostral;
- Pode extrapolar para distâncias não amostradas: permite estimar a variabilidade espacial para qualquer distância, isso é essencial para métodos como a krigagem;
- Disponibiliza parâmetros espaciais importantes: Nugget (indica a variabilidade de curta distância ou erro de medição), sill (Representa a variabilidade total da variável) e range (Define até que distância os dados estão correlacionados).

Estimação: Método dos Mínimos Quadrados

Na geoestatística, o modelo teórico do variograma precisa ser ajustado ao variograma empírico.
Quando os dados não seguem normalidade, a estimação por Máxima Verossimilhança (MV) pode não ser adequada, pois pressupõe distribuição normal. Nesses casos, utiliza-se o Método dos Mínimos Quadrados (MQ).

O MQ ajusta o modelo teórico minimizando:

$$\sum_h w(h)[\gamma_{\text{emp}}(h) - \gamma_{\text{teo}}(h)]^2$$

em que:

- $\gamma_{\text{emp}}(h)$ variograma empírico;
- $\gamma_{\text{teo}}(h)$ = modelo teórico;
- $w(h)$ = peso associado a cada distância.

Por que usar MQ quando não há normalidade?

- Não exige suposição de normalidade.
- Baseia-se apenas na estrutura de dependência espacial.
- Ajusta diretamente a forma do variograma.

Tipos de Mínimos Quadrados usados

- MQ Ordinário (OLS) – pesos iguais.
- MQ Ponderado (WLS) – pesos proporcionais ao número de pares.
- MQ Generalizado (GLS) – considera dependência entre estimativas.

Observação: neste minicurso utilizamos o MQ Ponderado (WLS) – pesos proporcionais ao número de pares.

Krigagem

A krigagem é uma técnica de interpolação baseada em modelos estatísticos e é usada para fazer previsões de valores em locais não amostrados, levando em consideração não apenas os valores observados, mas também a autocorrelação espacial, a ideia de que pontos próximos no espaço tendem a ser mais semelhantes entre si.

Como falado anteriormente, a krigagem faz uso do semivariograma para realizar as previsões.

Passos da Krigagem

1.Análise do semivariograma;

2. Modelagem do semivariograma;

3. Interpolação: A técnica calcula uma média ponderada dos pontos amostrados, onde os pontos mais próximos recebem maior peso na estimativa, levando em conta a estrutura espacial dos dados;

4. Estimativa de Erro: Em vez de fornecer apenas o valor estimado, a krigagem também gera uma mapa de incerteza que indica a precisão de cada estimativa, ajudando a identificar áreas com maior ou menor confiança nos resultados.

Tipos de Krigagem

Existem várias variantes da krigagem, dependendo do tipo de dado e do problema em questão:

- Krigagem Ordinária: A forma mais comum, onde se assume que a média da variável é constante em todo o domínio (sem tendência sistemática). É útil quando não se sabe a tendência global dos dados;

- Krigagem Universal: Usada quando há uma tendência no dado, como uma mudança sistemática no valor ao longo do espaço (por exemplo, uma elevação gradual ou uma inclinação). Esse modelo inclui uma tendência em sua formulação, além da dependência espacial;

- Krigagem de Múltiplos Padrões (Krigagem Co-krigagem): Utiliza múltiplas variáveis para fazer as estimativas, considerando que várias variáveis podem estar correlacionadas espacialmente, como o uso de dados de temperatura e umidade para prever a precipitação.

Vantagens da Krigagem

- Precisão: A krigagem pode fornecer estimativas precisas, pois leva em conta a estrutura espacial dos dados e a autocorrelação entre os pontos;

- Estimativa de erro: Além da estimativa dos valores, a krigagem também fornece uma medida da incerteza associada a cada estimativa, o que ajuda na tomada de decisões;

- Versatilidade: A krigagem pode ser aplicada a uma variedade de tipos de dados espaciais, incluindo dados contínuos e discretos.

Desvantagens e Limitações

- Complexidade computacional: A krigagem pode ser intensiva em termos computacionais, especialmente quando se trabalha com grandes volumes de dados, devido à necessidade de resolver sistemas de equações lineares;

- Modelo de variograma: O sucesso da krigagem depende da escolha adequada do modelo de variograma. Se o modelo não refletir corretamente a estrutura espacial dos dados, as estimativas podem ser imprecisas;

- Requer conhecimento de autocorrelação espacial: A krigagem pressupõe que a autocorrelação espacial seja um fenômeno importante, o que pode não ser o caso em algumas situações.

Validação Cruzada

A validação cruzada avalia o processo de predição por krigagem como um todo, desde o ajuste do variograma até a estimativa final.

Procedimento

- Divide-se o conjunto de dados em dois grupos:
  - Grupo de modelagem (treinamento) ⇝ usado para ajustar o variograma teórico.
  - Grupo de validação ⇝ usado para realizar as estimativas por krigagem.
- Calculam-se os resíduos:

$$e_i = z(x_i) - \hat{z}(x_i)$$

em que:

- $z(x_i)$ valor observado;
- $\hat{z}(x_i)$ valor estimado por krigagem.

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Objetivo

Avaliar a qualidade do modelo geoestatístico com base nas diferenças entre valores observados e estimados.

Critério de Avaliação

Espera-se que o melhor preditor seja aquele que:

- Produza menores resíduos;
- Apresente resíduos aleatoriamente distribuídos;
- Tenha média dos resíduos próxima de zero.

Isso indica ausência de viés e boa capacidade preditiva.

Tipos de Validação Cruzada

Existem diferentes formas de dividir os dados em conjuntos de modelagem e validação. As principais são:

Leave-One-Out (LOOCV):

- Retira-se um ponto por vez.
- O modelo é ajustado com os demais dados.
- O valor no ponto removido é estimado.
- Processo repetido para todas as observações.

Avaliação interna do modelo.

Two-Fold (Validação Externa):

- Divide-se o conjunto em dois grupos distintos:
- Um para ajuste do modelo;
- Outro para validação.

Avaliação mais independente da capacidade preditiva.

Observação: Neste minicurso foi utilizada a Validaçaõ cruzada Leave-One-Out (LOOCV).

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Aplicações de Geoestatística

Aplicação 1 – Mineração (Zhexenbayeva et al., 2024):

- O objetivo foi aplicar geoestatística de múltiplos pontos (Multiple-Point Statistics, MPS) para modelar a geometria complexa e continuidade de veios auríferos em um depósito de ouro.

- A variável resposta foi Teor de ouro (gold grade) e classificação de domínios geológicos (veios e rochas encaixantes) a partir de dados de sondagem.

- Multiple-Point Statistics (MPS) com o algoritmo DeeSse (Direct Sampling) para simulação de múltiplos pontos e captura de padrões complexos.

- A abordagem proposta produziu mapas de probabilidade espacial de ocorrência de domínios (ore vs waste), evidenciando a incerteza e padrões geológicos esperados.

Aplicações de Geoestatística

Aplicação 2 – Meteorologia (Guimarães; Alves, 2023):

- O objetivo foi comparar diferentes modelos geoestatísticos de variograma para estimar a precipitação em Minas Gerais, entre os anos hidrológicos de 2000 e 2021.
- A variável utilizada foi a precipitação acumulada (dados pluviométricos) dos anos hidrológicos analisados.
- Para interpolação utilizaram Krigagem Ordinária.
- Os modelos teóricos considerados foram
  - Gaussiano
  - Exponencial
  - Esférico
  - Circular e entre outros.
- O modelo Gaussiano apresentou melhor desempenho geral na estimativa da precipitação. O desempenho dos modelos variou conforme o período (estação seca vs. chuvosa). A geoestatística mostrou-se eficiente para mapear padrões espaciais de chuva e apoiar análises hidrológicas e planejamento ambiental.

Aplicações de Geoestatística

Aplicação 3 – Agricultura (Wani et al., 2024):

- O objetivo foi avaliar a heterogeneidade espacial de propriedades físico-químicas do solo em terras agrícolas na região temperada do Himalaia (Índia).
- As variáveis resposta foram os parâmetros físico-químicos do solo medidos em 206 amostras, das quais:
  - pH (acidez/ alcalinidade do solo)
  - Condutividade elétrica (EC)
  - Carbono orgânico (OC)
  - Nitrogênio disponível (N)
  - Fósforo disponível (P)
  - Potássio disponível (K)
  - Cálcio (Ca) e Magnésio (Mg)
- Para interpolação utilizaram Krigagem Ordinária.
- Os modelos teóricos utilizados foram o esférico, exponencial e matemático (a dependender da variável).
- A krigagem ordinária permitiu identificar zonas específicas com maior ou menor fertilidade, evidenciando padrões associados ao manejo e à topografia.

Aplicações de Geoestatística

Aplicação 4 – Saúde (Goovaerts, 2014):

- O objetivo do artigo não é um estudo empírico isolado, mas demonstrar como os métodos geoestatísticos desenvolvidos originalmente em mineração podem ser aplicados de forma coerente nas áreas de *medical geography* (epidemiologia espacial) e *medical geology*.

- O artigo não trata de uma única variável resposta experimental, mas usa como exemplo:
  - Concentração de arsênico em água subterrânea;
  - Taxas de incidência de câncer de próstata (em nível de município).

- Apresenta alguns métodos de interpolação característicos para a área.

- A geoestatística permitiu quantificar e modelar variabilidade espacial em conjuntos de dados altamente heterogêneos (ambiente e saúde), superando limites de métodos tradicionais de mapeamento.

Vamos à prática!!!

UTILIZAREMOS O SOFTWARE RSTUDIO PARA ESTA PRÁTICA. ACOMPANHEM CONOSCO!

SOBRE A APLICAÇÃO:

- Estudo econômico: valores cobrados por airbnbs no Rio de Janeiro (cidade) nos três primeiros meses de 2025;
- Dados disponíveis no Inside Airbnb;
- Seremos capazes de identificar e estimar locais com maiores valores.

Referências

GOOVAERTS, Pierre. Geostatistics: a common link between medical geography, mathematical geology, and medical geology. *Journal of the Southern African Institute of Mining and Metallurgy*, v. 114, n. 8, p. 605-613, 2014.

GUIMARÃES, Vinícius Lima; DE CARVALHO ALVES, Roberto. Comparação de modelos geoestatísticos para estimativa de precipitação em Minas Gerais, Brasil, entre os anos hidrológicos de 2000 e 2021. *Revista Brasileira de Geografia Física*, v. 16, n. 1, p. 528-541, 2023.

SCALON, J. D. *Análise de dados espaciais com aplicações em R*. Lavras: UFLA, 2024. 275 p. ISBN 978-85-8127-185-9.

WANI, Owais Ali et al. Geostatistical modelling of soil properties towards long-term ecological sustainability of agroecosystems. *Ecological Indicators*, v. 166, p. 112540, 2024.

ZHEXENBAYEVA, Aida et al. Using multiple-point geostatistics for geomodeling of a vein-type gold deposit. *Applied Computing and Geosciences*, v. 23, p. 100177, 2024.

Sugestão de Leitura:

J. D. SCALON

O livro Análise de Dados Espaciais com Aplicações em R oferece uma introdução completa à análise de dados espaciais, demonstrando como o uso de informações geográficas pode aprimorar pesquisas em diversas áreas. Com um enfoque prático e utilizando o software R, a obra é voltada para estudantes e profissionais de diferentes campos, como estatística, geografia, epidemiologia, biologia, agronomia, ecologia e meio ambiente.

O Grupo de Pesquisa em Estatística Espacial (GPS) foi criado em 2015 com o objetivo de proporcionar um ambiente para discussão e aprimoramento de estudos em Estatística Espacial. O grupo é composto por professores, ex-alunos, estudantes do programa de pós-graduação em Estatística e Experimentação Agropecuária da UFLA e de áreas afins.

Agradecimentos

UFLA
UNIVERSIDADE FEDERAL DE LAVRAS

CNPq

CAPES

Tem dúvidas? Pergunte!

SINTA-SE À VONTADE PARA TIRAR SUAS DÚVIDAS CONOSCO!

Daví Barbosa P. de Sousa; Marcela S. de Araujo - UFLA

Obrigado(a)!

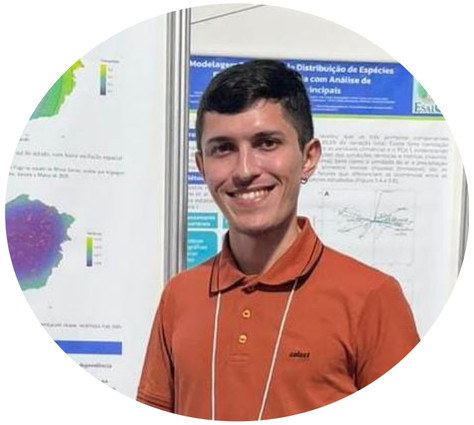

DAVÍ BARBOSA PEREIRA DE SOUSA

Doutorando em Estatística e Experimentação Agropecuária UFLA

Contatos:

Institucional: davi.sousa1@estudante.ufla.br

Profissional: davibarbosa.prof@gmail.com

Lattes: http://lattes.cnpq.br/4206431803366749

MARCELA SILVA DE ARAUJO

Doutoranda em Estatística e Experimentação Agropecuária UFLA

Contatos:

Institucional: marcela.araujo2@estudante.ufla.br

Profissional: marcelaaraujo.prof@gmail.com

Lattes: http://lattes.cnpq.br/8522510498165639